上市公司财报问答知识库 · 一页结论

方向 A ｜ 10 家医药公司 2025 年年报 ｜ 向量(bge-m3) + BM25 双路检索 + DeepSeek 带出处作答

> **一句话结论：**同一批财报，**「查数字、找口径、单公司事实」类问题适合建库**——答案必须可溯源、数字不容编造，检索系统的「带出处、不瞎说」恰好对症；而问题侧换词泛化（自营 vs 直销）和多实体并列召回是它的短板，需要图谱或查询改写补足。

系统规模

- 10 份年报全文（巨潮资讯）→ 约 470 万字正文 + 3,583 张表格（行列结构还原）→ **10,408 个知识块**（800 字 / 重合 120 / 句末收尾，块带公司·章节·页码标签，六大报表块带合并/母公司口径标签）
- 双路检索：bge-m3 向量（公司名+章节名拼入向量化文本） + jieba 金融词表 BM25，各取 Top20 → RRF 合并 Top5；问题先经 LLM 精炼（语义路）+ 抽关键词（关键词路）

10 题评估结果（每题检索召回与作答全文见 eval_results.md）

题型	结果	代表案例
单公司事实（5 题：营收/净利/现金流/研发占比/销售费用）	**5/5 对**	药明康德研发占比 2.46% —— 反直觉但与年报原文一致（CXO 客户资助研发计入成本），系统没有「想当然」
跨公司比较（2 题）	**1 对 / 1 拒答**	恒瑞 87.24 亿 vs 复星约 59 亿 研发投入，答对且注明口径；迈瑞 vs 联影题只召回了迈瑞一侧，模型如实说「信息不足」
口径陷阱（母公司 vs 合并）	**1/1 对**	「恒瑞**母公司**货币资金」准确命中母公司资产负债表（395.91 亿），未混入合并口径
换词陷阱（自营 vs 直销）	**0/1**	原文用「直销」，检索未把「自营」对齐，模型诚实拒答、未编造

哪类答得好、哪类翻车、为什么

答得好：带明确实体+指标的数字题	翻车：检索召回失败类（4 题中 3 题为拒答而非答错）

块级「公司+章节+页码」标签让出处可追溯；表格行列还原保住了数字（期间修复了 PyMuPDF 搅乱千分位数字、无边框报表取不到表两类解析坑）；模型被约束为「片段不足即拒答」，**10 题零编造**——答错的代价被转化成了「承认不知道」。	① 跨公司题双实体只召回一侧（向量路被「主要实体」主导）；② 同义换词超出字面匹配能力（BM25 打不中，向量在短语级也漂移）；③ 个别答案块元数据缺失（section「未知」页码空，为隔离 PyMuPDF 段错误的降级产物）。改进方向：查询改写/同义词典、双实体强制分组召回、图谱补足。

两类方案对比的小结（对应作业核心问题）

- **建库（本作业）赢在可信与可溯源**：知识可随时更新（换年报重跑即可）、每个数字能回到原文页码、拒答机制保证不出戏——凡是「要在真实业务里用」的场景，这些比流畅更重要。
- **微调赢在语气与格式内化**：适合「董秘口径」这类风格/话术类需求，但它无法保证数字新、出处准，且知识更新要重训。二者不互斥：微调管「怎么说」，建库管「说什么」。

技术栈：PyMuPDF + pdfplumber（提取/表格还原）· jieba + rank_bm25 + bge-m3（检索）· DeepSeek API（问题改写与作答）· Streamlit（问答页面）· 评估：10 题（2 跨公司 + 1 口径陷阱 + 1 换词陷阱），逐题记录召回块/答案/错因。核验方式：答案数字逐个放回知识库原文对证。